

2015 年家庭金融调查数据使用说明-补充

一、 数据清理

1、清理过程

数据采集回来后，中心会对所有数据进行初步处理，主要处理包括：删除由于访员严重臆答、作弊的无效样本，删除无效变量，删除敏感数据；校正人为导致的重复样本编号，校正访员主动报备的人为误操作；合并追踪和新访数据，拆分家庭和个人数据，拆分多选；加注标签，加注问卷类型；清理备注和其他选项，数值题插值及相关规则确定等。

经过初步处理后数据生成可使用的版本。在数据使用过程中如再发现极值或异常值，中心会进行二次录音核查确认。如果没有录音，则通过创建模型处理极值和异常值，从而更新数据版本并告知用户。

2、数据存储

数据清理结束，生成的中国家庭金融调查数据存储有以下 3 个数据集里面。

1. 数据集文件名中含有“**hh**”，代表问卷中家庭部分的数据，例如：资产与负债，家庭的支出与收入，金融知识、基层治理与主观评价等；
2. 数据集文件名中含有“**ind**”，代表问卷中个人部分的数据，例如：人口统计特征（部分），个人工作及收入信息，保险与保障，家庭成员教育等；
3. 数据集文件名中含有“**master**”，代表是地区数据，具体包括调查的省份信息和每次调查数据的权重变量。

除此之外原始数据使用格式对应为 dta 格式（可用 stata13.0【最佳版】或以上版本打开）。

二、 变量命名规则

家庭金融调查问卷数据的变量名由首位的字母及后面四位数字构成，不同的首字母对应问卷的不同部分（如，b-农业/工商业；d-金融资产），一些特别的标识性变量（id 变量、城乡、省份等）则根据它们的含义被重新命名以便使用。部分变量在原变量名后加上后缀字母

it, 表示对前一个问题的数值范围追问。问卷中的每个问题前均给出了对应的变量名称, 需要特别注意的变量及其命名规则说明如下:

1、id 变量

id 变量分为家庭变量 (hhid) 和个体变量 (pline):

hhid 是标识家庭的变量。每一个 hhid 代表一个家庭; hhid 可唯一识别家庭。pline 是标识每个家庭中家庭成员的变量。每一个 pline 代表一个家庭成员; hhid 和 pline 可唯一识别个体, 同一个家庭同一个家庭成员不同时期的 pline 保持不变。

2、权重变量 (swgt)

在我们的抽样设计下, 由于每户家庭被抽中的概率不同, 因此每户家庭代表的中国家庭数量也就不同。在推断总体的时候, 需要通过权重的调整来真实准确地反映每户样本家庭代表的家庭数量, 以获得对总体的正确推断。中国家庭金融调查的所有计算结果都经过抽样权重的调整。在 master 数据集中含有权重变量: swgt。

其抽样权重的计算方法如下: 根据每阶段的抽样分别计算出调查市县被抽中的概率 p_1 、调查社区 (村) 在所属区县被抽中的概率 p_2 以及调查样本在所属社区 (村) 被抽中的概率 p_3 , 分别计算出三阶段的抽样权重 $w_1=1/p_1$ 、 $w_2=1/p_2$ 、 $w_3=1/p_3$, 最后得到该样本的抽样权重为 $w=w_1 \times w_2 \times w_3$ 。

即 $swgt=$ 这个社区被抽中概率的倒数。

3、变量中的其他选项

在数据变量单选题或多选题中, 一般情况下最后 1 个选项为“其他 (请注明)”。若受访者选择了该选项, 对应会多问 1 道填空题。在 2015 年家庭金融调查数据中, 该新生成的变量命名格式为: 原变量后加上后缀_ex1, 例如: b1001c_ex1 表示受访户属于的农业生产经营户类型是其他相关农业生产经营户信息。

4、循环问题

对于所有循环询问的问题，命名规则为在原变量名后加上后缀_#；#代表第#次循环。例如，c2003_1 表示第一套房子的建筑面积；c2003_2 则表示第二套房子的建筑面积。部分循环问题的变量列表如下：

表 1 循环问题的变量列表

变量名称	循环次数	变量信息
b3001-b3054it	2	varname_1 农业贷款 varname_2 工商业贷款
c2000-c2000ait	3	varname_#家庭第#套房的房产信息
c2003-c2022	3	varname_#家庭第#套房的房产信息

注：问卷中还包含其他由于加载而产生的循环，如 c5004hf 等，在此不一一列出。

5、多项选择题

对于多项选择题，处理原则为将每一个选项转换为取值为 0 和 1 的哑变量。多项选择题分为两类：非循环多项选择题、循环多项选择题。

(1) 非循环多项选择题

非循环多项选择题的命名规则为在原变量名后加上后缀_*_mc；*代表第*个选项。例如，b1004_1_mc 表示是否勾选 b1004 的第一个选项“粮食作物”；0 表示未选择，1 表示选择。非循环多选问题的变量列表如下：

表 2 非循环多选题的变量列表

变量名称	多选个数	变量名称	多选个数	变量名称	多选个数
a4007d	6	c1000ba	15	d7113	6
a4007f	6	c1013	9	e1007aa	8
a4007g	5	c3004a	10	e1020aa	8
a4007i	5	c3017d	10	e2002ab	6
a4007k	9	c5001a	6	e2004a	8
a4007q	5	c5004he	13	e2006	6
a4007r	5	c5007e	7	e2013a	6
a4007s	6	c5014a	9	e2013b	5
a4012	8	c5015a	7	e2019a	14
a4013	8	c5021	6	e2020b	4
a4026	11	c5024	6	e3003	9
a4028	6	c5027	4	e3005b	9
a4030	11	c5033	8	e3016	7

b1001c	6	c5033a	8	e3020	5
b1004	6	c5034	9	e3021a	8
b1004b	6	c5040	5	g1009b	13
b1004c	12	c7071	14	g2002	10
b1004g	17	c8001	17	g2004	7
b1009	6	c8004	7	h1002	10
b1014a	4	d2107	7	h1004	8
b1017	14	d2108	9	h2001	12
b1102	5	d2118	10	h2003	8
b1104	11	d2118a	9	h3014	5
b1105	7	d2118b	7	h3024	3
b1106	11	d2126	7	h3045	7
b1107b	9	d2130	10	j2001	6
b1108	6	d3102aa	10	j2004	5
b1116	6	d3105a	10	j2011	4
b2000c	8	d3111b	9	k2119	9
b2008	6	d4101a	5	a3049a	8
b2078	13	d5102aa	11	a3052	15
b2083c	7	d5104	5	f2001a	12
b3055a	4	d7106e	11	f6001	4
b3061	5	d7106g	8		

表 3 非循环多选题处理说明

varname_*_mc	变量信息
0	第*个选项未选择
1	第*个选项已选择

(2) 循环多项选择题

循环多项选择题的命名规则为在原变量名后加上后缀_*_#_mc；*代表第*个选项，#代表第#次循环。例如，b3002a_2_1_mc 表示在第一次循环时是否勾选第二个选项“估计贷款申请不会被批准”；0 表示未选择，1 表示选择。循环多选问题的变量列表如下：

表 4 循环多选题的变量列表

变量名称	多选个数	循环次数	变量名称	多选个数	循环次数
b3002a	9	2	b1001d	3	3
b3003	9	2	c2005a	3	3
b3012	10	2	c2010d	10	3
b3014a	8	2	c2011b	3	3
b3021c	8	2	c2000ai	10	6
b3021d	7	2	c2000ak	3	6
b3027a	8	2	c2000ap	3	6

表 5 循环多选题处理说明

varname_ *_#_mc	变量信息
0	在第#次循环中第*个选项未选择
1	在第#次循环中第*个选项已选择

6、插值变量

为了解决数据缺失问题，我们对所有题目里含“it”的题进行了插值处理。对于插值后的变量，命名规则为原变量名加上后缀_imp，插值问题的变量列表如下：

表 6 插值问题的变量列表

变量名称				
b1004h_#_imp	b3030c_#_imp	a3037_imp	c2027d_imp	d7112_imp
b1004_#_imp	b3031a_#_imp	f1005_imp	c2032_imp	d8104_imp
b2036_#_imp	b3044_#_imp	f1010_imp	c2041_imp	d8106_imp
b2037_#_imp	b3044a_#_imp	f1031_imp	c3002_imp	d9100aa_imp
b3002b_#_imp	b3051_#_imp	f1036_imp	c3002a_imp	d9100b_imp
b3005_#_imp	b3054_#_imp	f2006_imp	c3016_imp	d9110a_imp
b3005a_#_imp	c2000a_#_imp	f4005_imp	c3003_imp	d9110b_imp
b3008_#_imp	c2000f_#_imp	f4008_imp	c3017ca_imp	d9108_imp
b3008f_#_imp	c2013_#_imp	f4011_imp	c3019a_imp	e1006_imp
b3018_#_imp	c2016_#_imp	b1005b_imp	c3019c_imp	e1006a_imp
b3020_#_imp	d4103_#_imp	b1012_imp	c3019e_imp	e1007a_imp
b3022a_#_imp	b1004h_#_imp	b1013a_imp	c3024_imp	e1016_imp
b3022b_#_imp	b1004_#_imp	b1013c_imp	c3025_imp	e1022_imp
b3030c_#_imp	c2000a_#_imp	b1013e_imp	c7009_imp	e1021_imp
b3031a_#_imp	c2000f_#_imp	b1014_imp	c7022_imp	e1034_imp
b3044_#_imp	c2013_#_imp	b1015a_imp	c7023_imp	e1027_imp
b3044a_#_imp	c2016_#_imp	b2021_imp	c7077_imp	e1046_imp
b3051_#_imp	d4103_#_imp	b2022_imp	c7078_imp	e3003c_imp
b3054_#_imp	b1004h_#_imp	b2040_imp	c7052b_imp	e3005c_imp
c2000a_#_imp	b1004_#_imp	b2041_imp	c8007_imp	e3019_imp
c2000f_#_imp	c2000a_#_imp	b2046_imp	d1105_imp	e4003_imp
c2013_#_imp	c2000f_#_imp	b2050_imp	d2104_imp	e4004_imp
c2016_#_imp	d4103_#_imp	b2052_imp	d2106_imp	e4005_imp
d4103_#_imp	b1004h_#_imp	b2055_imp	d3103_imp	e4006_imp
b1004h_#_imp	b1004_#_imp	b2059_imp	d3109_imp	e4018_imp
b1004_#_imp	c2000a_#_imp	b2063_imp	d3110_imp	g1014_imp
b2036_#_imp	c2000f_#_imp	b2080_imp	d3116_imp	g1015_imp
b2037_#_imp	d4103_#_imp	b2084_imp	d3117_imp	g1017_imp

b3002b_#_imp	b1004h_#_imp	b2085_imp	d4111_imp	g1018_imp
b3005_#_imp	b1004_#_imp	b2093_imp	d5107_imp	g1019_imp
b3005a_#_imp	c2000a_#_imp	b2103_imp	d5108_imp	g1019a_imp
b3008_#_imp	c2000f_#_imp	b2110_imp	d5109_imp	h2004_imp
b3008f_#_imp	a3020_imp	c2002d_imp	d6100a_imp	k1101_imp
b3018_#_imp	a3022_imp	c2023d_imp	d6116_imp	k2102b_imp
b3020_#_imp	a3023_imp	c2027a_imp	d7106a_imp	k2114_imp
b3022a_#_imp	a3024_imp	c2027b_imp	d7106h_imp	
b3022b_#_imp	a3036_imp	c2027c_imp	d7110_imp	

7、截尾处理

根据统计法规定，为保护受访者隐私，我们对收入和资产的极值进行了截尾处理。将收入或资产超过某一规定值的样本替换为该规定值，并同时给出一个截尾处理的哑变量，命名规则为变量名加上前缀 `ensor_`，即 `ensor_varname`。例如，我们将 2011 年家庭金融调查数据的年收入（`hh_income`）在 300 万以上的替换为 300 万，并同时给出一个哑变量 `ensor_hh_income`，0 表示未进行处理；1 表示进行了截尾处理。

表 7 截尾处理说明

<code>ensor_varname</code>	变量信息
0	未处理
1	已处理

8、其它特殊变量说明

表 7 特殊变量说明

变量名称	变量取值	变量取值含义	补充说明
hhead	0	非户主	
	1	户主	
respond	0	非受访者	remark 变量： 无法判断受访者的样本在 remark 变量里做了备注说明
	1	受访者	
rural	0	城镇	
	1	农村	
istrack	0	新访	
	1	追访	
aorb	a	a 卷	
	b	b 卷	

region	1	东部	北京、天津、河北、辽宁、上海、江苏、浙江、福建、山东、广东、海南
	2	中部	山西、吉林、黑龙江、安徽、江西、河南、湖北、湖南
	3	西部	内蒙、广西、重庆、四川、贵州、云南、陕西、甘肃、青海、宁夏

9、资产、负债、收入、消费变量说明

家庭总资产（asset）包括非金融资产（nfasset）和金融资产（fasset）。非金融资产包括农业经营资产、工商业经营资产、土地资产、房产、车辆资产、其他非金融资产。金融资产包括社保账户余额、现金、存款、股票、基金、债券、衍生品、理财、外币资产、黄金、其他金融资产和借出款。

家庭总负债（debt）包括农业负债、工商业负债、房产负债、车辆负债、其他非金融资产负债、股票负债、其他金融资产负债、教育负债、医疗负债和其他负债。

家庭总收入（total_income）包括工资性收入、农业经营收入、工商业经营收入、转移性收入和投资性收入。

家庭消费性支出（total_consump）包括食品支出、衣着支出、居住支出、生活用品及服务支出、教育娱乐支出、交通通信支出、医疗保健支出和其他支出。

10、部分缺失值说明

实际访问受主客观因素影响，由于受访者主观知识以及态度、访员理解或填答错误等原因，不可避免的会产生少量的缺失值。这些缺失值定义如下：

1. 数据值为“.d”

受访户不知道如何回答。访员选择了“不知道”（该选项实际问卷题目中没有）。由于不知道造成的缺失。

2. 数据值为“.r”

受访户拒绝回答该问题，访员选择了“拒绝回答”（该选项实际问卷题目中没有）。由于拒绝回答造成的缺失。

三、 问卷分批分卷说明

1、 问卷分批次说明

因调查访问期间学生分两轮派出，第二批次学生派出时，2015 年家庭金融调查问卷进行了修改，具体调整变量列表如下所示：

表 8 分批次问卷变量说明

序号	类型	第一批问卷	第二批问卷
1	删除变量	a3037、a3037it	删除 a3037、a3037it
2	删除变量	b1014aa、b1014ab、b1014ac、 b1014ad	删除 b1014aa、b1014ab、 b1014ac、b1014ad
3	删除变量	b1009	删除 b1009
4	删除变量	c1000ac	删除 c1000ac
5	删除变量	c5003a、c5004	删除 c5003a、c5004
6	删除变量	c5004h	删除 c5004h
7	删除变量	c5004hd、c5004he、c5004hf、 c5004hf_01、c5004hg	删除 c5004hd、c5004he、c5004hf、 c5004hf_01、c5004hg
8	删除变量	c5004hm、c5004hn、c5004hp	删除 c5004hm、c5004hn、c5004hp
9	删除变量	c5040、c5043、c5044、c5045、 c5046、c5047、c5048、c5049	删除 c5040、c5043、c5044、 c5045、c5046、c5047、c5048、 c5049
10	删除变量	c7008a	删除 c7008a
11	删除变量	b1115、b1116	删除 b1115、b1116
12	添加变量	无 a4007a-a4007t 金惠问卷	添加 a4007a-a4007t 金惠问卷
13	调整顺序	a2018b、a2019a、a2019b	顺序改为：a2019b、a2019a、 a2018b
14	调整顺序	a2025b、a2025ba、a2025bb	顺序改为：a2025ba、a2025bb、 a2025b
15	调整选项	b3012:1-8 选项，8 为其他选项	b3012: 1-10 选项，10 为其他选 项，增加：8 宅基地、9 集体林权
16	调整选项	b2001a:1-5 选项，5 为其他选项	b2001a:1-6 选项，6 为其他选项， 增加：5 继承家业
17	调整选项	b3061:1-4 选项，3 保证金、4 其他	b3061:1-5 选项，3 保证担保、4 预 付保证金、5、其他
18	调整选项	b3060	b3060: 增加选项 3.不愿意/不需要 从银行贷款
19	调整选项	g1009b:1-10 选项，10 为其他选 项	g1009b:1-13 选项，12 为其他选 项，增加：10 接打电话、11 收发 短信、13 以上功能都未使用

20	调整选项	h3055 是否接受季度电话回访	h3055 愿意接受电话回访的频率： 月度、季度、半年度、年度、不愿意
21	修改题型	c1000af 多选	c1000af 填空
22	询问条件再设置	a3014a=3 时询问 a3015	a3014a=3 时不询问 a3015
23	询问条件再设置	a3014a=3 时不询问 a3018a	a3014a=3 时询问 a3018a
24	询问条件再设置	b1001a 城镇、农村皆问	b1001a 只问农村样本
25	询问条件再设置	c8006-c8007it 无询问限制条件	c8006-c8007it 仅在 c8001≠18 或 c8004≠7 时询问
26	询问条件再设置	d3101-d3117it 无询问限制条件	d3101-d3117it 在 a4007=3 或 5 时不询问
27	询问条件再设置	d5102-d5109it 无询问限制条件	d5102-d5109it 在 a4007=4 或 5 时不询问
28	询问条件再设置	a1001-a1009 无询问限制条件	a1001-a1009 阿里样本不询问
29	询问条件再设置	a2032-a2041	a2032-a2041 仅询问 60 岁及以下受访者
30	询问条件再设置	a2042	a2042 在 a2035b=2 时不询问

2、问卷分卷说明

2015 年家庭金融调查问卷有部分变量分 a 卷、b 卷进行询问，具体分卷的变量列表如下所示：

表 9 划分 a/b 卷变量说明

仅 a 卷	仅 b 卷
a4012、a4014、a4016、a4017、 a4020、a4022、a4024、a4026、 a4026a、a4026b、a4030、a4032、 a4034、c1000ac、c1000ab、c1000ac、 c1000ad、c1000ae、c1000af、 c1000ag、c1000ah、c1000ai、 c1000ba、c1000bb、c1000bc、c4001、 c4002、c4004、c4005、c4006、 c4007、c4007a、c4008、c4008b、 c4008c	a4013、a4015、a4015a、a4018、 a4019、a4021、a4023、a4025、 a4027、a4027a、a4027b、a4027c、 a4031、a4033、a4035、b2056、 c2000ae、c2000af、c2000ag、 c2000ah、c2000ai、c2000aj、 c2000ak、c2000al、c2005a、c2010a、 c2010b、c2010c、c2010ca、c2010d、 c2010da、c2010e、c3018、c3019、 c3019aa、c3019a、c3019ait、 c3019b、c3019c、c3019cit、c3019d、 c3019e、c3019eit、c3024、c3024it、 c3025it、c3025it

