

第 1 章 CHFS 项目简介

中国家庭金融调查（China Household Finance Survey, CHFS）是西南财经大学中国家庭金融调查与研究中心（以下简称“中心”）在全国范围内开展的抽样调查项目，旨在收集有关家庭金融微观层次的相关信息，旨在系统、可持续性地建设包括家庭、社区在内的具有全国代表性、省级代表性的高质量中国微观主体数据库，为相关领域的学术研究、政策制定、业界发展与创新等提供基础数据支撑。

中国家庭金融调查数据库主要涵盖：个人基本信息与就业、金融资产和非金融资产（农业、工商业、住房、土地、家庭耐用品等）、家庭负债、家庭收入和支出、社会保障与保险等相关信息，对家庭经济、金融行为进行了全面细致刻画。

本调查于 2011 年启动，每两年追踪调查一次，目前已形成 2011、2013、2015、2017、2019 年五轮调查数据。各轮调查样本情况如下表所示。

表 1 中国家庭金融调查历次调查样本情况

年份	省份	区县	社区	家庭	个人	样本代表性
2011	25	80	320	8438	29324	全国
2013	29	267	1048	28141	97906	全国、省份
2015	29	351	1396	37289	133183	全国、省份、副省级城市
2017	29	355	1428	40011	127012	全国、省份、副省级城市
2019	29	345	1360	34643	107008	全国、省份

第 2 章 抽样方案介绍

2019 年中国家庭金融调查项目采用了分层、三阶段与规模度量成比例（PPS）的抽样设计。第一阶段采用分层人口规模比例概率（PPS）抽样方法抽取区县（包括市辖区、县级市、县等各类县级行政区），第二阶段在区县内等距抽取居委会/村委会，第三阶段在居委会/村委会内随机抽取住户。本次调查项目具体抽样过程如下：

（1）确定目标样本量

在各个省份最低样本量的计算过程中，根据历史经验和主要研究内容，拟定最大可容许误差为均值的 10%，置信度拟定为 0.05。考虑复杂抽样下的设计效应，结合 CHFS 历年调查数据，以家庭总收入、家庭总消费、家庭总资产等关键性指标为准，计算出各省具有省级代表性的最低样本量。然后，结合调查当年经费预算、执行难度、研究需求等因素，向上调整确定出各省目标样本量和全国目标样本量，最终实现省级代表性和全国代表性。

（2）第一阶段：抽取区县

为降低第一阶段抽样误差，采用分层 PPS 抽样方法抽取样本区县，项目组将在抽样前尽可能多搜集与项目调研主题相关的外部统计指标数据，通过关键统计指标对抽样单元进行分层抽样，以保证样本结构与总体结构尽可能一致。首先将省内所有区县按照人均 GDP 排序后进行分层，各省分层数量根据省内区县数

量确定，各省区层层数一般为 7~9 层。然后，再在层内采用 PPS 抽样方法抽取样本区县，每层内抽取的区县数为 1~3 个。第一阶段抽样，可以有效保证各省抽中区县在经济发展水平上的分布尽可能均匀，保证样本具有较好的省级代表性。

（3）第二阶段：抽取社区

第二阶段在区县内部抽取居委会/村委会。区县内抽取社区数量为 4 个。具体而言，在抽中的各区县内部，将区县社区划分为城镇社区和农村社区抽样框，根据各区县的城镇化率，确定目标城镇和农村社区数量，然后根据统计局公布的社区行政区划代码排序，进行随机起点、等距抽样。

（4）第三阶段：抽取住户

在居委会/村委会内部随机抽取家庭。本次调查项目在农村社区抽取的住户数量为 20~30 户，城镇社区抽取住户数量为 25~35 户。住户抽取方法为先通过绘制社区行政边界范围内的住户分布图，排除空户后获得末端抽样清单。最后在末端抽样清单内，采用随机抽样的方式抽取住户样本。在实际调查过程中，如遇特殊情况不能访问抽中住户，按照严格的随机抽样原则，从剩余样本池里抽取替换样本，直至完成目标样本量。在末端抽样中，要尽可能争取社区的配合协助，以获取完整的社区住户清单，以保证样本的覆盖率和准确率。

第 3 章 样本分布情况

CHFS2019 合格样本共计 34643 户家庭，样本城乡分布情况、样本地区分布情况、样本省份分布情况，分别如下所示。

表 2 样本城乡分布情况

城乡	样本量	占比
城镇	22381	64.60%
乡村	12262	35.40%
总计	34643	100%

表 3 样本地区分布情况

地区	样本量	占比
东部	12930	37.32%
中部	7532	21.74%
西部	10471	30.23%
东北	3710	10.71%
总计	34643	100%

表 4 样本省份分布情况

省份	样本量	占比
上海市	1200	3.46%
云南省	1124	3.24%
内蒙古自治区	900	2.60%
北京市	1112	3.21%
吉林省	947	2.73%
四川省	1662	4.80%
天津市	932	2.69%
宁夏回族自治区	687	1.98%
安徽省	1250	3.61%
山东省	1209	3.49%
山西省	1162	3.35%
广东省	1907	5.50%
广西壮族自治区	1107	3.20%
江苏省	1374	3.97%
江西省	928	2.68%
河北省	1431	4.13%
河南省	1377	3.97%
浙江省	1447	4.18%
海南省	1265	3.65%
湖北省	1287	3.72%
湖南省	1528	4.41%
甘肃省	881	2.54%

福建省	1053	3.04%
贵州省	893	2.58%
辽宁省	1401	4.04%
重庆市	1291	3.73%
陕西省	1111	3.21%
青海省	815	2.35%
黑龙江省	1362	3.93%
总计	34643	100%

第 4 章 数据库介绍

4.1 数据清理简介

1、数据采集回来后，由质控部进行初步核查处理，主要包括：

- (1) 标注无效样本，例如，由于访员严重臆答的样本等。
- (2) 校正人为导致的重复样本编号。
- (3) 校正访员主动报备的人为误操作。
- (4) 校正录音核查发现的人为误录入等。

2、数据部继续深入清理，主要包括：

- (1) 样本层面：删除未完成、重复、无效、不合格、质量不高等样本。
- (2) 问卷变量层面：处理问卷及其衍生变量、检查并转换缺失值、变量类型转换、添加变量标签、检查并处理非法选项（单选题）、检查并处理非法值域（填空题）、异常值复核及修正、添加值标签。
- (3) 非问卷变量层面：处理样本标识变量、处理行政区划信息变量、处理其他系统性非问卷变量、综合变量（收入、消费、资产、负债）计算、目标缺失变量插补、计算并调整权重变量等。

3、出具技术文档，如数据清理报告，数据说明类文档等。

4.2 数据集介绍

完成清理后的中国家庭金融调查数据，主要存储在以下 4 个数据集之中：

(1) 家庭数据集，在数据中通过“hh”字段标识。该数据集汇集了家庭层面的问卷信息，如家庭各类资产、负债拥有情况及家庭消费支出情况等信息。例如：家庭农业、工商业生产经营情况、住房资产拥有情况等。

(2) 个人数据集，在数据中通过“ind”字段标识。该数据集汇集了家庭成员（即个体）层面的问卷信息，包括个人基本信息、个人就业状况、社会保障和商业保险等信息。

(3) 家庭综合数据集，在数据中通过“master_hh”字段标识。该数据集包含了基于问卷数据衍生的家庭层面的非问卷变量。主要包括样本地理信息，家庭权重，家庭资产、负债、收入以及消费等信息。这些家庭层面的变量对家庭所有成员均保持一致。

(4) 个人综合数据集，在数据中通过“master_ind”字段标识。该数据集包含了基于问卷数据衍生的个人层面的非问卷变量。主要包括个人权重。

数据存储格式为 stata14 版本，建议使用 stata14 及以上版本软件打开。

4.3 样本标识变量

样本标识变量：家庭样本标识变量（hhid）和个人样本标识变量（pline）。

hhid 是标识家庭的变量。每一个 hhid 代表一个家庭，可唯一识别家庭，同一家庭在不同年份的 hhid 保持不变。

pline 是标识每个家庭中家庭成员的变量。每一个 pline 代表一个家庭成员，hhid 和 pline 可唯一识别个体，同一个家庭中的同一个家庭成员不同时期的 pline 保持不变。

通过 hhid 和 pline，可以实现同一年份不同数据集之间的精确匹配，进行跨数据集的深入分析，也可以实现跨年匹配。

在家庭数据集中，hhid 是唯一、不可重复的，但在个人数据集中，hhid 会有重复值，因其包含了一个家庭中的多个成员，而 hhid 结合 pline 是唯一、不可重复的。

4.4 地理信息变量

4.4.1 城乡标识变量

rural：城乡标识变量。若 rural=1，则代表乡村地区；若 rural=0，则代表城镇地区。

关于城乡的定义¹，城镇：城镇包括城区和镇区。城区是指在市辖区和不设区的市，区、市政府驻地的实际建设连接到的居民委员会和其他区域。镇区是指在城区以外的县人民政府驻地和其他镇，政府驻地的实际建设连接到的居民委员会和其他区域。与政府驻地的实际建设不连接，且常住人口在 3000 人以上的独立的工矿区、开发区、科研单位、大专院校等特殊区域及农场、林场的场部驻地视为镇区。乡村：乡村是指城镇以外的区域。

4.4.2 地区分类变量

根据受访样本的地理信息，创建了以下三类不同口径的地理变量。

category：城乡分类代码²。以 1 开头的表示是城镇，以 2 开头表示是乡村。具体含义如下：111 表示主城区，112 表示城乡结合区，121 表示镇中心区，122 表示镇乡结合区，123 表示特殊区域；210 表示乡中心区，220 表示村庄。

region：东中西东北部分类³。东部包括：北京、天津、河北、上海、江苏、浙江、福建、山东、广东和海南。中部包括：山西、安徽、江西、河南、湖北和湖南。西部包括：内蒙古、广西、重庆、四川、贵州、云南、西藏、陕西、甘肃、青海、宁夏和新疆。东北包括：辽宁、吉林和黑龙江。

¹ 《统计上划分城乡的规定》：http://www.stats.gov.cn/tjsj/tjbz/200610/t20061018_8666.html

² 统计上如何确定城镇和乡村：http://www.stats.gov.cn/ztc/zthd/lhfw/2021/rdwt/202102/t20210225_1814028.html

³ 《东西中部和东北地区划分方法》：http://www.stats.gov.cn/ztc/zthd/sjtr/dejtkfr/tjkp/201106/t20110613_71947.htm

city_level: 一二三线城市分类⁴。由第一财经根据商业资源集聚度、城市枢纽性、城市人活跃度、生活方式多样性、未来可塑性五个板块乘以相应的权重计算所得。一线城市包括：上海、北京、深圳、广州；新一线城市：成都、杭州、重庆、西安、苏州、武汉、南京、天津、郑州、长沙、东莞、佛山、宁波、青岛、沈阳。二线城市包括：合肥、昆明、无锡、厦门、济南、福州、温州、大连、哈尔滨、长春、泉州、石家庄、南宁、金华、贵阳、南昌、嘉兴、珠海、南通、惠州、太原、中山、徐州、绍兴、常州、台州、烟台、兰州、潍坊、临沂。其余城市归为三线及以下城市。（以上排名划分先后顺序）

4.4.3 行政区划变量

综合数据集中的行政区划信息变量，代表的是抽样住址，是指基于抽样设计，样本家庭第一次接受访问时的常住地址。

一般而言，对于同一家庭，在不同轮次调查的抽样地址保持不变。对于每轮调查中首次被抽中的家庭，抽样地址等于常住地址；对于每轮调查中的追踪家庭，如果追踪家庭搬离了首次被抽中时的常住地，这时候抽样地址不再等于常住地址。据统计，总体而言，抽样地址相对于常住地址，1%左右的样本家庭抽样地址和常住地址在省市层面存在差异，5%在区县层面存在差异。

4.5 系统字段变量

4.6 问卷及其衍生变量

4.6.1 年龄变量

CHFS 问卷中与家庭成员出生年份相关的变量有三个。

第一个是 a1106c，主要是对追踪受访户的原有家庭成员进行确认。

第二个是 a1114，主要是对追踪受访户的新增家庭成员进行询问。

第三个是 a2005，包含追踪家庭和新访家庭成员的出生年份信息。

因此，可以直接通过 a2005 这一变量，计算：家庭成员年龄=接受访问的年份-出生年份。

4.6.2 其他（注明）变量

（1）选择题中，有些问题设置了“其他（请注明）”选项，对应取值设置为“7777”。若受访者选择了该选项，一般会继续追问需要注明的信息，该信息被存储在一个新的变量中。命名规则：原变量后加上后缀_ex1。

例如：[C3017b] 抵押贷款的用途是？

- | | |
|--------------------|--------------|
| 1.维持工商业经营与生存 | 2.创业/开启新的 |
| 3.购买住房 | 4.日常消费 |
| 5.金融市场投资（股票、理财产品等） | 7777.其他（请注明） |

⁴ 第一财经新一线城市研究所《2021 城市商业魅力排行榜》：<https://www.yicai.com/news/101063860.html>

c3017b_ex1: 表示受访户抵押贷款用途的其他相关信息, 且具体内容是访员注明的信息。

(2) 除此之外, 个别选择题设置了“以上都没有”选项, 对应取值为“7788”, 即对于问卷列出的所有选项, 受访户均不符合。

例如: [c1013] 租金中包含下列哪些费用?

- | | |
|------------|--------|
| 1. 水费 | 2. 电费 |
| 3. 燃料费 | 4. 物业费 |
| 5. 光纤费 | 6. 电话费 |
| 7. 网络费 | 9. 暖气费 |
| 7788. 都不包括 | |

4.6.3 循环变量

命名规则: 在原变量名后加上后缀“_#”; “#”代表第#次循环。

(1) 根据访题选项进行循环。

例如, [D5104a] 从投资标的看, 您家拥有的基金有哪些类型? [可多选]

- | | |
|-------------|----------------|
| 1. 股票型 | 2. 债券型 |
| 3. 货币市场基金 | 4. 混合型 |
| 5. QDII 型 | 6. 商品型 |
| 7. 指数型或 ETF | 7777. 其他 (请注明) |

[D5107] 目前, 您家拥有的【系统循环加载 D5104a 所选选项】基金的总市值是多少钱? (单位: 元)

D5107 循环加载了变量 D5104a 的选项, d5104a 的选项 1 为“股票型”, 选项 7777 为“其他 (请注明)”, 因此, d5107_1 表示股票型基金的总市值, d5107_7777 表示其他类型基金的总市值。

(2) 根据第几套房子进行循环。

例如, c2003_1 表示第一套房子的建筑面积; c2003_2 则表示第二套房子的建筑面积。

(3) 根据农业/工商业进行循环。

命名规则: 农业相关问题, 原变量名后加上后缀“_1”, 工商业相关问题, 原变量名后加上后缀“_2”。

例如: b3030d_1 表示农业生产经营的民间借款计划借款额, b3030d_2 表示工商业生产经营的民间借款计划借款额。

例如: b3001ab_#_*, #表示依次循环 b3001ab 的加载变量 b3001aa 的选项, “*”则表示农业/工商业的循环。b3001ab_1_1 表示农业生产经营中, 来自银行、信用社的经营欠款未还金额, 相应地, b3001ab_1_2 则表示工商业生产经营中, 来自银行、信用社的经营欠款未还金额。b3001ab_2_1 表示农业生产经营中, 来自亲朋好友的经营欠款未还金额, b3001ab_2_2 则表示工商业生产经营中, 来自亲朋好友的经营欠款未还金额。

(4) 根据家庭成员进行循环。

例如: [B2099a] 请问下列哪些家庭成员参与该项目的生产经营管理 (包括受访者)?

加载 16 周岁及以上的家庭成员列表

7777. 没有家庭成员参与管理【跳至 B2102】

B2099a 涉及加载家庭成员列表,因此,我们在个人数据集里对应的生成变量 b2099a_*_mc,b2099a_*_mc 的取值为 0 或 1, b2099a_*_mc 取值为 1 时,表示家庭成员*参与了项目的生产经营管理,取值为 0 则表示未参与。

4.6.4 多选变量

(1) 多选原变量

若数据库中某个多选变量的具体取值为“1-2-3-6”,则代表受访者在回答该题目时,选择了 1、2、3、6 共四个选项。

(2) 多选拆分变量

对于多项选择题,处理原则为将每一个选项转换为取值为 0 和 1 的哑变量。

命名规则:原变量名后加上后缀“*_mc”。“*”代表第*个选项。若取值为 1,则代表受访者回答该题时,选择了第*个选项。

1) 非循环多选

命名规则:原变量名后加上后缀“*_mc”。“*”代表第*个选项。

例如:[B1004] 去年,您家从事了哪些农业生产经营?

1.种植粮食作物

2.种植经济作物

3.林木种植和采运

4.畜禽养殖

5.水产养殖和捕捞

7777.其他(请注明)

b1004_1_mc 表示是否勾选 b1004 的第一个选项“粮食作物”,0 表示未选择,1 表示选择。

b1004_2_mc 表示是否勾选 b1004 的第二个选项“经济作物”,0 表示未选择,1 表示选择。

2) 循环多选

命名规则:原变量名后加上后缀“#*_mc”;“#”代表第#次循环,“*”代表第*个选项。

例 1: b1100b_2_1_mc 表示在第二次循环(种植经济作物)时是否勾选第一个选项“直接销售”,即受访户去年种植的经济作物是否用于直接销售,0 表示未选择,1 表示选择。

例 2: e3005dh_7_2_mc 表示在第七次循环(日常消费)时是否勾选第二个选项“亲朋好友”,即因日常消费产生的信贷需求,是否要通过亲朋好友渠道借入所需资金,0 表示未选择,1 表示选择。

4.7 截尾变量

为保护受访者隐私,我们对部分变量的极值进行了截尾处理,将超过某一限定值的样本替换为该限定值,同时给出一个截尾处理的哑变量。

命名规则:原变量名加上后缀_censor,即 varname_censor,0 表示未进行处理;1 表示进行了截尾处理。

例如,chfs2019 数据中,变量 a3136(个人去年税后货币工资),将 100 万以上的替换为 100 万,并同时给出一个哑变量 a3136_censor,0 表示未进行处理;1 表示进行了截尾处理。

chfs2019 截尾变量的相关情况如下表所示。

表 5 截尾变量列表

变量名	截尾标准	截尾样本数
a3136_imp	1000000	1
a3136a	1000000	1
a3136a_imp	1000000	3
a3136aa	1000000	2
a3136aa_imp	1000000	2
b2003a	10000000	8
b2003a_imp	10000000	10
b2003b	10000000	4
b2003b_imp	10000000	5
b2003d	10000000	2
b2003d_imp	10000000	2
b2050	10000000	26
b2050_imp	10000000	33
b2052	10000000	22
b2052_imp	10000000	27
b2055	5000000	7
b2055_imp	5000000	10
b2059	5000000	9
b2059_imp	5000000	10
b2063	5000000	4
b2063_imp	5000000	4
b2080	5000000	7
b2080_imp	5000000	7
c2016_2	10000000	3
c2016_2_imp	10000000	4
c2016_4	10000000	20
c2016_4_imp	10000000	33
c2016_5	10000000	5
c2016_5_imp	10000000	7
c3019a	5000000	4
c3019a_imp	5000000	4
c7009ags	150000	2
c7009ags_imp	150000	2
c7052b	2000000	4
c7052b_imp	2000000	5
c2071a	1000000	1
c2071a_imp	1000000	2
c7024a_1_imp	500000	1
c8001ab_exinteger2	1000000	1
c8001ab_exinteger3	1000000	2
c8001ab_exinteger4	1000000	6
c8001ab_exinteger9	1000000	1
c8001ab_exinteger11	1000000	1

变量名	截尾标准	截尾样本数
c8001ab_exinteger19	1000000	1
d1105	5000000	3
d1105_imp	5000000	7
d2104	5000000	2
d2104_imp	5000000	2
d3116_imp	2500000	1
d5107_3_imp	500000	1
d5107_4_imp	1000000	1
d7110a	5000000	2
d7110a_imp	5000000	3
d8104	5000000	2
d8104_imp	5000000	2
d9103	5000000	1
d9103_imp	5000000	1
k1101	2000000	1
k1101_imp	2000000	1
k2102c	5000000	3
k2102c_imp	5000000	3
e1001ab_2	1000000	2
e1001ab_2_imp	1000000	2
e3002a_1	1000000	5
e3002a_1_imp	1000000	5
e3002a_2	1000000	9
e3002a_2_imp	1000000	9
f1028	200000	1
f1028_imp	200000	1

4.8 综合变量

CHFS 数据库中综合变量主要包含：家庭总收入（total_income）、家庭总消费（total_consump）、家庭总资产（total_asset）和家庭总负债（total_debt），均属于项目组自行汇总生成的家庭层面变量，对于同一户的所有家庭成员，这些变量取值是相同的。由于不同年份问卷问法差异以及计算口径的细节变化，各年数据库中综合变量的具体内涵可能存在差异。

4.8.1 家庭收入变量

家庭总收入反映了调查时点的前一年（例如，2019 年调查搜集的是公历 2018 年全年的收入信息）家庭所获得的总收入，涵盖 5 项，包括工资性收入、农业收入、工商业收入、财产性收入和转移性收入。工资性收入指家庭成员通过雇佣关系获得的税后工资、奖金和补贴。农业收入指家庭从事农业生产经营活动后扣除成本的净收入（包括实物折现）。工商业收入指家庭通过个体经营等活动获得的税后净利润。财产性收入指家庭基于自有的房产、土地、金融资产等获得的净收入。转移性收入包括家庭成员的退休金、社会

救济、私人转移等收入。CHFS 数据库中，部分家庭可能出现负收入的情况，通常源于生产经营活动亏损或金融市场投资损失，该情况与家庭负债无直接关联。

1、2019 年家庭总收入计算如下：

家庭总收入 = 工资性收入 + 农业收入 + 工商业收入 + 财产性收入 + 转移性收入

(1) 工资性收入 (hhwage_inc)

工资性收入 = 加总所有家庭成员的工资收入。其中，工资收入包括每位家庭成员主要工作的税后工资、税后奖金、税后补贴，以及其他工作的收入。

(2) 农业收入 (agri_inc)

农业收入 = 农业毛收入-农业成本+农业补贴。其中，农业毛收入=max（农业总产值，农产品销售收入+消费自产农产品价值）；农业成本包括购买农资品、雇佣工人、租赁农机和其他农业生产经营费用。

(3) 工商业收入 (busi_inc)

工商业收入=去年倒闭或者被合并工商业项目的税后净收入+家庭所有工商业项目税后净收入+家庭唯一工商业项目税后净收入。其中，家庭唯一工商业项目税后收入使用占股比例和盈亏状况调整。

(4) 财产性收入 (prop_inc)

财产性收入=出租收入+金融投资收入+房屋拆迁收入+土地征收收入。其中，出租收入包括房屋出租、商铺出租、土地流转、宅基地出租等收入。

(5) 转移性收入 (transfer_inc)

转移性收入=政府转移收入+私人转移收入+商业保险报销或赔付+其他收入。其中，政府转移收入包括养老金收入、失业保险金收入、提取或使用住房公积金和政府救助或补贴。

2、2019 年家庭总收入调整如下：

为进一步提升数据准确性，CHFS2019 基于上述初始收入变量，根据受访者自答分项收入信息，对家庭收入进行了如下调整：

(1) 将 CHFS 初始计算的各分项收入与受访者自答的对应分项收入 (h3001aa_*) 进行逐一比对；

(2) 若受访者自答分项收入金额高于 CHFS 初始计算值（其中，经营性收入需高于 CHFS 初始计算值的 1.5 倍），则用自答金额替换初始计算值，若受访者未对该分项收入做出回答，则保留初始计算值。

调整后的收入变量包括：家庭总收入 (total_income_adj)、工资性收入 (hhwage_inc_adj)、农业收入 (hhwage_inc_adj)、工商业收入 (busi_inc_adj)、财产性收入 (prop_inc_adj) 和转移性收入 (transfer_inc_adj)。

初始收入变量和调整后的收入变量，都将在家庭综合数据集 (master_hh) 中进行提供。

4.8.2 家庭消费变量

家庭总消费反映调查时点前一年家庭发生的所有消费性支出，涵盖 8 项，包括食品消费、衣着消费、居住消费、家庭设备服务消费、交通通信消费、教育文娱消费、医疗保健消费和其他消费。需要注意的是，CHFS 计算的家庭总消费仅包括消费性支出，不包括财产性、经营性、社会保障和转移性支出。经营性支出已在农业、工商业收入中扣除。根据不同支出类型的发生频率，CHFS 采用全年和平均每月进行询问。综合消费变量以全年为基准，若原始数据为每月平均值，则乘以 12 转换为全年数据。

(1) 食品消费 (food_con)

食品消费 = 食品支出+ 烟酒支出+ 消费自产农产品价值。

(2) 衣着消费 (food_con)

衣着消费 = 过去十二个月购买衣物之和。

(3) 居住消费 (resident_con)

居住消费 = 房屋租金 + 水电燃料、物业管理费 + 房屋装修维修支出。

(4) 家庭设备服务消费 (equipment_con)

家庭设备服务消费 = 耐用品支出+日常用品支出+个人护理支出+家政服务支出+文娱消费品支出

(5) 交通通信消费 (travel_con)

交通通信消费 = 交通工具支出 + 交通费 + 通信费支出。其中，交通工具支出包括购买家用汽车支出和其它交通工具支出；交通费包括本地交通费、长途交通费和家庭汽车使用费（含燃料、保养费、停车费）；通信费包括购买及维修通信工具支出和话费、上网费与邮递服务费。

(6) 教育文娱消费 (educ_con)

教育文娱消费 = 文化娱乐支出 + 教育培训支出 + 旅游支出。

(7) 医疗保健消费 (medical_con)

医疗保险消费 = 保健支出 + 医疗支出。

(8) 其他消费 (other_con)

其他消费 = 购买高价值资产支出 + 其他支出。

4.8.3 家庭资产变量

家庭总资产反映调查时点的家庭资产存量，包括金融资产和非金融资产。

金融资产 (finc_asset) 包括存款、现金、股票、基金、债券、理财产品、衍生品、非人民币资产、贵金属、其它金融资产和借出款。

非金融资产包括农业资产 (agri_asset)、工商业资产 (busi_asset)、房屋资产 (hous_asset)、商铺资产 (shop_asset)、土地资产 (land_asset)、车辆资产 (vehicle_asset)、车库资产 (garag_sset) 和耐用品及高价值资产 (dura_asset)。

4.8.4 家庭负债变量

家庭总负债反映调查时点的家庭负债存量。根据用途主要分为农业负债 (agri_debt)、工商业负债 (busi_debt)、房屋负债 (hous_debt)、商铺负债 (shop_debt)、车辆负债 (vehicle_debt)、耐用品及高价值资产负债 (dura_debt)、金融产品投资负债 (finc_debt)、教育负债 (educ_debt)、医疗负债 (medical_debt) 和其他负债 (other_debt)。各项负债包括银行机构贷款和民间等渠道借款。研究者可以将家庭总资产减去家庭总负债得到家庭净资产。

4.9 插值变量

4.9.1 数据缺失

总体来讲，调查数据缺失的主要原因，一是受访者的无回答，二是访员的失误。具体到 CHFS，在实际访问过程中，由于受访者的认知差异，配合程度，回答意愿，以及访员的理解差异，记录错误等原因，而导致的数据缺失，又可以具体细分为以下几个方面：

（1）当受访者由于不知道如何回答时而造成的缺失，CHFS 数据中将其赋值为“.d”。注：“不知道”选项在问卷中不显示，在访问时系统中会显示。

（2）当受访者由于拒绝回答该问题时而造成的缺失，CHFS 数据中将其赋值为“.r”。注：“拒绝回答”选项在问卷中不显示，在访问时系统中会显示。

（3）当访员错误记录了受访者回答的信息时，在后期的核查过程中，核查员会根据核查信息纠正该问题的答案，但与此同时，可能会导致后续新生成一系列需要受访者进一步回答的问题，而这些问题，是受访者在事先访问过程中未被询问到的，由此而造成的缺失，CHFS 数据中将其赋值为“.e”。

（4）当访员自行猜测受访者的答案，而实际上，受访者本身并未就该问题给出答案，在后期的核查过程中，核查员发现其为访员臆答，那么该答案将会被取消，由此而造成的缺失，CHFS 数据中将其赋值为“.n”。

另外，需注意，CHFS 数据中还有赋值为“.”的（文本型变量取值对应表现为空白），这一类并不属于 CHFS 数据中定义的缺失值。因为 CHFS 问卷中很多题目设有条件限制，不满足条件设置的受访者无需回答该类问题，问卷系统会自动跳转过这些问题，对于不满足该条件设置的受访者来说，此类问题可视为无意义的题目，或者不适用、或不需要回答的题目，其存在并不影响数据的完整性。

4.9.2 插值方法

处理数据缺失是确保数据集完整性和分析准确性的关键步骤，CHFS 主要对数据中的金额类定比变量进行插值。在实际插值过程中，运用的主要方法如下：

（1）若目标变量的缺失值存在对应的有效区间，那么一般采用区间回归法（Interval Regression Intreg）对其进行多重插补，通常情况下，插补 5 次，并取 5 次插补结果的平均值作为缺失值的最终插补值。

（2）若目标变量的缺失值不存在对应的有效区间，那么一般采用预测均值匹配法（Predicted Mean Matching）对其进行多重插补，通常情况下，插补 5 次，并取 5 次插补结果的平均值作为缺失值的最终插补值。

插值模型中协变量的选取：一是能够很好预测缺失数据的变量，比如年龄、性别、教育这三个重要的与数据缺失有关的变量，二是后续研究分析模型中会用到的，与目标缺失变量相关的变量。

4.9.3 插值变量

最终，数据库中的每个目标缺失变量，均会生成以下与插值相关的变量：

（1）原变量名后加上后缀_imp，表示原变量插补后的对应变量的。

（2）原变量名后加上后缀_imp_dummy，表示原变量是否插值的哑变量，0 代表未插值，1 代表已插值。

4.10 权重变量

在使用调查数据推断总体情况时，我们根据抽样方案计算了抽样权重，修正由于非等比例分配社区样本量等因素造成的抽样偏差。

在我们的抽样设计下，由于每户家庭被抽中的概率不同，因此每户家庭代表的中国家庭数量也就不同。在推断总体的时候，需要通过权重的调整来真实准确地反映每户样本家庭代表的家庭数量，以获得对总体的正确推断。中国家庭金融调查的所有计算结果都经过抽样权重的调整。权重的计算，根据每阶段的抽样分别计算出调查区县被抽中的概率 P_1 、调查社区（村）在所属区县被抽中的概率 P_2 以及调查样本在所属社区（村）被抽中的概率 P_3 ，分别计算出三阶段的概率，最终权重等于三阶段概率乘积的倒数，具体计算公式如下：

$$weight_{ijk} = \frac{1}{p_1 p_2 p_3} = 1 / \left(\frac{n_i}{N_i} \times \frac{n_{ij}}{N_{ij}} \times \frac{n_{ijk}}{N_{ijk}} \right)$$

其中， p_1 、 p_2 、 p_3 分别代表第一阶段中区县被抽中的概率，第二阶段中社区被抽中的概率，第三阶段中社区中样本单元被抽中的概率。 n_i 为第 i 层的所有抽中区县人口数； N_i 为第 i 层的所有区县总人口数； n_{ij} 为第 i 层第 j 个区县所有抽中社区人口数； N_{ij} 为第 i 层第 j 个区县的总人口数； n_{ijk} 为第 i 层第 j 个区县第 k 个社区的抽中人口数； N_{ijk} 为第 i 层第 j 个区县第 k 个社区的总人口数。

考虑到抽样设计的复杂性、实际调查过程中问题多样性，导致调查样本城乡、性别、年龄比例等分布的不均衡，使得样本存在结构性偏差。在计算出抽样设计权重后，我们还将进一步使用官方数据，对抽样权重进行调整，进一步修正调查样本的结构性偏差。

最终，综合数据集中会提供权重相关变量：家庭权重（`wgt_hhadj`）、个人权重（`wgt_ind`）、三阶段权重（`wgt_phase1`、`wgt_phase2`、`wgt_phase3`）。

第 5 章 数据使用建议

由于 CHFS 的变量丰富且变量之间的关系复杂，若不加以仔细处理，则容易出现分析错误和结论偏差。为更合理地使用中国家庭金融调查数据，提高研究结果的准确性和可信性，建议研究者在使用数据时注意以下几个方面。

（一）了解数据

在进行数据分析之前，研究者应全面了解数据的来源、结构和内容。建议仔细阅读问卷，全面掌握每个访题的具体含义、适用范围以及逻辑跳转规则，重点了解研究涉及的访题在不同年份的问法差异，这是确保数据使用准确性的基础。建议研究者详细阅读数据使用手册、综合变量构建说明等资料，以准确把握数据集的划分、样本标识变量的作用和变量的命名规则等。

（二）清洗数据

虽然项目组发布的数据已经经过了多轮清洗，基于不同的研究目标，研究者在生成分析变量的过程中，依然有必要对数据展开进一步清洗处理，应特别注意以下几个方面：

第一，处理缺失值。研究者需要明确区分前文介绍的逻辑性缺失和实际性缺失，并采取适当的方法进行处理。

第二，处理极端值。极端值可能会对数据分析结果产生显著影响，因此需要进行识别和处理。研究者可以采用截尾处理、进一步插值等方法来处理极端值，以确保数据分析的准确性和可靠性。

第三，清理“其他”选项。对于选择类变量中的“其他”选项，如果记录了详细备注信息，研究者可以根据具体内容进行重新分类，并将其纳入相应的变量中，以提高原始变量的完整性和准确性。

第四，变量跨年统一。在进行跨年分析时，需要注意变量的一致性。在问卷设计过程中，项目组尽量保障同一访题的内涵在各年基本不变，但是依然可能存在访题的具体询问内容、询问范围、选项编码在不同年份有差异的情况，导致变量取值含义在各年不完全可比。因此在进行跨年数据分析时，建议研究者先逐年生成口径尽可能一致的研究变量，然后再进行跨年变化的分析。特别是对于主观态度类的问题，一般由受访者给出答案，而各年受访者都可能发生变化，如果要直接比较这类变量的跨年变化，建议先将分析限定在跨年受访者不变的样本中。

（三）数据分析与结果验证

在数据清洗完毕之后，研究者还需要进一步对数据进行分析，以确保研究结果的有效性。

首先，查看变量的取值特征和分布情况。在正式进行数据分析之前，研究者应查看变量的取值特征和分布情况，识别可能存在的异常值和数据偏差。这有助于在数据分析过程中采取适当的统计方法，确保分析结果的准确性和可靠性。

其次，选择合适的统计方法。根据数据的特征和研究问题的需求，选择合适的统计方法进行分析。研究者应结合 CHFS 数据的特点，灵活运用各种统计方法和模型，以揭示数据背后的经济和金融规律。

再次，进行结果验证和敏感性分析。为了确保研究结果的稳健性，研究者应进行结果验证和敏感性分析。通过改变分析方法、调整模型参数或使用不同的样本，验证结果的一致性和可靠性，以增强研究结论的可信度。

中国家庭金融调查与研究中心

数据部